

**ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT
KHOA TOÁN KINH TẾ**



TIỂU LUẬN CUỐI KÌ

**Môn: Giới thiệu về học máy
(Lớp 252BMA400601)**

**ỨNG DỤNG HỌC MÁY TRONG ĐỊNH GIÁ ĐIỆN THOẠI
THEO THÔNG SỐ KỸ THUẬT**

**Giảng viên hướng dẫn: Th.S Trương Quang Nhật
Sinh viên thực hiện: Đỗ Ngọc Bảo Kha
MSSV: K244191961**

TP Hồ Chí Minh, tháng 04 năm 2026

MỤC LỤC

Contents

CHƯƠNG I: MỞ ĐẦU	5
1.1. Động lực nghiên cứu (Research Motivation)	5
1.2. Tổng quan các nghiên cứu trước (Literature Review)	5
1.3. Khoảng trống nghiên cứu (Research Gap)	6
1.4. Mục tiêu nghiên cứu (Research Objectives)	6
1.4.1. Mục tiêu tổng quát	6
1.4.2. Mục tiêu cụ thể	6
1.5. Câu hỏi nghiên cứu (Research Questions)	7
1.6. Đối tượng và phạm vi nghiên cứu	7
1.6.1. Đối tượng nghiên cứu	7
1.6.2. Phạm vi nghiên cứu	7
1.7. Phương pháp nghiên cứu	7
CHƯƠNG 2: GIỚI THIỆU DATA	9
2.1. Nguồn gốc thu thập dữ liệu	9
2.2. Mô tả dữ liệu	9
2.3. Phân loại và vai trò của các biến số	10
2.3.1. Biến phụ thuộc (Y)	10
2.3.2. Biến độc lập định lượng (Xqt)	10
2.3.3. Biến độc lập định tính (Xql)	11
2.3.4. Biến không sử dụng / cần loại bỏ (tránh data leakage)	11
2.3.5. Biến phát sinh (Feature Engineering)	11
CHƯƠNG 3: GIỚI THIỆU VỀ MÔ HÌNH	12
3.1. Tổng quan về Machine Learning	12
3.1.1. Khái niệm Machine Learning	12
3.1.2. Supervised Learning	12
3.1.3. Bài toán hồi quy (Regression Problem)	13
3.2. Các mô hình Học máy được sử dụng trong nghiên cứu	13
3.2.1. Hồi quy tuyến tính (Linear Regression)	13

3.2.2. Cây quyết định (Decision Tree)	14
3.2.3. Random Forest	14
3.2.4. XGBoost (Extreme Gradient Boosting)	15
3.3. Hàm mất mát và chỉ số đánh giá	16
3.3.1. Mean Absolute Error (MAE)	16
3.3.2. Root Mean Squared Error (RMSE)	16
3.3.3. Hệ số xác định (R^2)	16
3.4. Quy trình xây dựng mô hình	17
3.5. Tối ưu hóa siêu tham số (Hyperparameter Tuning)	Error! Bookmark not defined.
3.5.1. Grid Search	Error! Bookmark not defined.
3.5.2. Random Search	Error! Bookmark not defined.
3.5.3. Genetic Algorithm (Nâng cao)	Error! Bookmark not defined.
CHƯƠNG 4: XỬ LÝ DỮ LIỆU	18
4.1. Tiền xử lý dữ liệu	18
4.1.1. Kiểm tra dữ liệu rỗng	18
4.1.2. Xử lý dữ liệu trùng	18
4.1.3. Chuẩn hóa dữ liệu	19
4.1.4. Loại bỏ dữ liệu sai	19
4.1.5. Kiểm tra tương quan	19
4.1.6. Loại bỏ biến	20
4.2. Phân tích dữ liệu (EDA)	21
4.2.1. Phân phối histogram	21
4.2.2. Boxplot	22
4.2.3. Scatter	23
4.2.4. Average price by phone_brand	24
4.2.4. Performance	25
4.2.4. Pairplot	26
CHƯƠNG 5: MÔ HÌNH HÓA DỮ LIỆU ĐÁNH GIÁ MÔ HÌNH	27
5.1. Chia dữ liệu	27
5.2. Linear Regression	27

5.2.1. Phân tích chỉ số hiệu năng (Metrics)	27
5.2.2. Phân tích bảng hệ số (Coefficients)	28
5.2.3. Phân tích biểu đồ phần dư (Residual Plot)	29
5.3. Decision Tree	29
5.3.1. Hiện tượng Overfitting (Quá khớp) cực đoan	29
5.3.2. Phân tích bảng so sánh giá trị dự báo	30
5.3.3. Phân tích biểu đồ phần dư (Residual Plot)	31
5.3.4. Đánh giá tính ứng dụng trong nghiên cứu	31
5.4. Random Forest	32
5.4.1. Phân tích chỉ số hiệu năng (Metrics) - Sự cải thiện vượt trội	32
5.4.2. Khả năng kiểm soát Overfitting	32
5.4.3. Phân tích biểu đồ phần dư (Residual Plot)	33
5.5. XGBoost	34
5.5.1. Phân tích chỉ số hiệu năng (Metrics) - Đỉnh cao mới	34
5.5.2. Khả năng tổng quát hóa (Generalization)	34
5.5.3. Phân tích bảng giá trị dự báo (Predictions)	34
5.5.4. Phân tích biểu đồ phần dư (Residual Plot)	35
5.5.5. Trực quan hóa	36
5.6. So sánh mô hình	37
5.6.1. Bảng so sánh tổng hợp (Tập Test)	37
5.6.2. Nhận xét chi tiết từng mô hình	37
5.6.3. Phân tích các yếu tố ảnh hưởng (Feature Importance)	38
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	39
6.1. Kết luận	39
6.2. Đóng góp của nghiên cứu	39
6.3. Hạn chế của nghiên cứu	40
6.4. Hướng phát triển trong tương lai	41
6.5. Kết luận chung	42

CHƯƠNG I: MỞ ĐẦU

1.1. Động lực nghiên cứu (Research Motivation)

Trong bối cảnh công nghệ phát triển mạnh mẽ, thị trường điện thoại thông minh (smartphone) đã trở thành một trong những lĩnh vực cạnh tranh nhất trong ngành điện tử tiêu dùng. Sự đa dạng về thương hiệu, cấu hình và mức giá khiến cho người tiêu dùng gặp nhiều khó khăn trong việc xác định giá trị thực của một sản phẩm. Đồng thời, các doanh nghiệp và nhà bán lẻ cũng đối mặt với thách thức trong việc định giá sản phẩm một cách hợp lý nhằm tối đa hóa lợi nhuận và nâng cao khả năng cạnh tranh trên thị trường.

Giá của một chiếc điện thoại không chỉ phụ thuộc vào một yếu tố đơn lẻ mà là sự kết hợp của nhiều đặc điểm kỹ thuật như bộ nhớ RAM, dung lượng lưu trữ, dung lượng pin, chất lượng camera, vi xử lý và các yếu tố thương hiệu. Mối quan hệ giữa các yếu tố này và giá bán thường mang tính phi tuyến và phức tạp, khiến cho các phương pháp phân tích truyền thống khó có thể mô hình hóa chính xác.

Trong những năm gần đây, học máy (Machine Learning) đã nổi lên như một công cụ mạnh mẽ trong việc khai thác dữ liệu và xây dựng các mô hình dự đoán hiệu quả. Nhờ khả năng học từ dữ liệu và phát hiện các mối quan hệ tiềm ẩn, các thuật toán học máy có thể hỗ trợ dự đoán giá sản phẩm với độ chính xác cao hơn so với các phương pháp truyền thống.

Xuất phát từ thực tiễn đó, đề tài “Ứng dụng học máy trong dự đoán giá điện thoại dựa trên thông số kỹ thuật” được lựa chọn nhằm khai thác tiềm năng của học máy trong việc giải quyết bài toán định giá sản phẩm, đồng thời cung cấp các insight có giá trị cho cả người tiêu dùng và doanh nghiệp.

1.2. Tổng quan các nghiên cứu trước (Literature Review)

Bài toán dự đoán giá đã được nghiên cứu rộng rãi trong nhiều lĩnh vực như bất động sản, tài chính và thương mại điện tử. Trong giai đoạn đầu, các phương pháp thống kê truyền thống như hồi quy tuyến tính (Linear Regression) được sử dụng phổ biến nhờ tính đơn giản và dễ triển khai. Tuy nhiên, các mô hình này thường giả định mối quan hệ tuyến tính giữa biến đầu vào và biến mục tiêu, do đó gặp hạn chế khi xử lý dữ liệu có tính phi tuyến cao.

Sự phát triển của học máy đã mở ra nhiều hướng tiếp cận mới cho bài toán dự đoán giá. Các thuật toán như Decision Tree, Random Forest và Gradient Boosting đã chứng minh khả năng xử lý tốt các mối quan hệ phi tuyến và tương tác phức tạp giữa các biến. Đặc biệt, các mô hình ensemble như Random Forest và XGBoost thường cho kết quả dự đoán chính xác hơn nhờ khả năng giảm overfitting và cải thiện tính tổng quát hóa.

Bên cạnh đó, một số nghiên cứu gần đây còn tập trung vào việc tối ưu hóa siêu tham số (hyperparameter tuning) nhằm nâng cao hiệu suất mô hình. Các phương pháp như Grid Search, Random Search và các thuật toán tối ưu hóa tiến hóa (ví dụ: Genetic Algorithm) được sử dụng để tìm ra cấu hình tối ưu cho mô hình.

Tuy nhiên, phần lớn các nghiên cứu hiện tại tập trung vào các lĩnh vực phổ biến như bất động sản hoặc thị trường tài chính, trong khi bài toán dự đoán giá điện thoại thông minh vẫn chưa được khai thác sâu, đặc biệt trong bối cảnh dữ liệu thực tế tại thị trường Việt Nam.

1.3. Khoảng trống nghiên cứu (Research Gap)

Mặc dù đã có nhiều nghiên cứu về dự đoán giá bằng học máy, vẫn tồn tại một số khoảng trống cần được giải quyết:

Thứ nhất, số lượng nghiên cứu chuyên sâu về dự đoán giá điện thoại còn hạn chế, đặc biệt là các nghiên cứu sử dụng dữ liệu thực tế với nhiều biến kỹ thuật đa dạng.

Thứ hai, nhiều nghiên cứu chưa thực hiện so sánh toàn diện giữa các mô hình học máy khác nhau để xác định mô hình tối ưu cho từng loại dữ liệu cụ thể.

Thứ ba, vấn đề tối ưu hóa siêu tham số chưa được khai thác đầy đủ trong một số nghiên cứu, dẫn đến hiệu suất mô hình chưa đạt mức tối ưu.

Thứ tư, các nghiên cứu trước thường tập trung vào độ chính xác dự đoán mà chưa chú trọng nhiều đến việc phân tích mức độ ảnh hưởng của từng yếu tố kỹ thuật đến giá sản phẩm.

Do đó, đề tài này được thực hiện nhằm góp phần lấp đầy những khoảng trống nêu trên thông qua việc xây dựng và đánh giá các mô hình học máy trong bài toán dự đoán giá điện thoại.

1.4. Mục tiêu nghiên cứu (Research Objectives)

1.4.1. Mục tiêu tổng quát

Mục tiêu tổng quát của nghiên cứu là xây dựng và đánh giá các mô hình học máy nhằm dự đoán giá điện thoại dựa trên các thông số kỹ thuật, từ đó xác định mô hình có hiệu suất tốt nhất và rút ra các yếu tố ảnh hưởng quan trọng đến giá sản phẩm.

1.4.2. Mục tiêu cụ thể

- Thu thập và phân tích dữ liệu về điện thoại thông minh với các đặc điểm kỹ thuật liên quan.

- Thực hiện tiền xử lý dữ liệu nhằm đảm bảo chất lượng đầu vào cho mô hình.
- Xây dựng và huấn luyện các mô hình học máy như Linear Regression, Decision Tree, Random Forest và XGBoost.
- Đánh giá và so sánh hiệu suất của các mô hình dựa trên các chỉ số như MAE, RMSE và R^2 .
- Phân tích tầm quan trọng của các biến đầu vào đối với giá điện thoại.
- Đề xuất hướng cải tiến mô hình trong tương lai.

1.5. Câu hỏi nghiên cứu (Research Questions)

Nghiên cứu này được thực hiện nhằm trả lời các câu hỏi sau:

1. Những yếu tố kỹ thuật nào có ảnh hưởng lớn nhất đến giá điện thoại?
2. Mô hình học máy nào cho kết quả dự đoán chính xác nhất trong bài toán này?
3. Việc sử dụng các mô hình học máy có cải thiện đáng kể độ chính xác so với phương pháp truyền thống hay không?
4. Mức độ ảnh hưởng của từng biến đầu vào đến kết quả dự đoán là như thế nào?

1.6. Đối tượng và phạm vi nghiên cứu

1.6.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học máy được sử dụng để dự đoán giá điện thoại dựa trên các thông số kỹ thuật của sản phẩm.

1.6.2. Phạm vi nghiên cứu

- Dữ liệu sử dụng trong nghiên cứu bao gồm các thông tin về cấu hình điện thoại như RAM, dung lượng lưu trữ, pin, camera và các đặc điểm liên quan.
- Nghiên cứu tập trung vào các mô hình học máy phổ biến trong bài toán hồi quy.
- Không xem xét các yếu tố bên ngoài như xu hướng thị trường, chiến lược marketing hoặc yếu tố tâm lý người tiêu dùng.

1.7. Phương pháp nghiên cứu

Để đạt được các mục tiêu đề ra, nghiên cứu sử dụng các phương pháp sau:

Phương pháp nghiên cứu lý thuyết

Tổng hợp và phân tích các tài liệu liên quan đến học máy, bài toán hồi quy và các mô hình dự đoán giá.

Phương pháp thực nghiệm

Xây dựng và huấn luyện các mô hình học máy trên tập dữ liệu thực tế, sau đó đánh giá hiệu suất thông qua các chỉ số định lượng.

Phương pháp so sánh và đánh giá

So sánh kết quả giữa các mô hình nhằm xác định mô hình tối ưu và phân tích nguyên nhân dẫn đến sự khác biệt về hiệu suất.

CHƯƠNG 2: GIỚI THIỆU DATA

2.1. Nguồn gốc thu thập dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu có tên là “MobilePhone”, được tổng hợp từ hệ thống niêm yết và thông số kỹ thuật của các nhà bán lẻ điện thoại di động trực tuyến lớn,. Dữ liệu phản ánh thông tin chi tiết về cấu hình và giá bán thực tế của các thiết bị, với quy mô hơn 2.180 dòng dữ liệu, tương ứng với các mẫu điện thoại được ra mắt trong giai đoạn từ tháng 11 năm 2017 đến tháng 10 năm 2024.

Nguồn dữ liệu này được công bố công khai trên nền tảng học liệu mở Kaggle bởi tác giả Alireza Mohammadi, nhằm phục vụ mục đích học tập, nghiên cứu và phân tích xu hướng công nghệ. Bộ dữ liệu được xây dựng để hỗ trợ việc phân tích mối tương quan giữa sức mạnh phần cứng và giá trị sản phẩm, phục vụ trực tiếp cho bài toán dự báo giá bán dựa trên các thông số kỹ thuật như RAM, bộ nhớ, và kích thước thiết bị.

Việc thu thập dữ liệu được thực hiện thông qua phương pháp trích xuất dữ liệu từ các nền tảng thương mại điện tử phổ biến, tiêu biểu là Amazon Đức (DE) (chiếm 34%) và Amazon Anh (UK) (chiếm 28%). Sau khi thu thập, dữ liệu đã được làm sạch, chuẩn hóa các đơn vị tiền tệ (sang USD và EUR) và lưu trữ dưới định dạng CSV (processed_data.csv) để thuận tiện cho việc huấn luyện các mô hình học máy và xử lý thống kê.

2.2. Mô tả dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu là MobilePhone Dataset, bao gồm thông tin về cấu hình và giá của các dòng điện thoại.

- Số quan sát: 1715 dòng
- Số biến: 31 biến

STT	Tên biến	Mô tả
2.2.1. Nhóm biến định danh (Identification variables)		
1	phone_brand	Hãng sản xuất
2	phone_model	Tên model điện thoại
3	store	Nơi bán
2.2.2. Nhóm biến giá và tiền tệ		
4	price	Giá gốc
5	currency	Đơn vị tiền tệ
6	price_USD	Giá quy đổi USD
2.2.3. Nhóm biến thông số kỹ thuật (Technical variables)		
7	storage	Bộ nhớ trong (GB)
8	ram	RAM (GB)
9	Chipset	Chip xử lý

10	CPU	Bộ xử lý
11	GPU	Bộ xử lý đồ họa
12	Display_Type	Loại màn hình
13	Display_Size	Kích thước màn hình
14	Display_Resolution	Độ phân giải
15	PPI_Density	Mật độ điểm ảnh
16	BATTERY	Dung lượng pin
17	USB	Chuẩn kết nối USB
18	NFC	Hỗ trợ NFC
19	Dimensions	Kích thước máy
20	Weight	Trọng lượng
21	Colors	Màu sắc
22	Foldable	Có gập được hay không
23	OS	Hệ điều hành
24	Features_Sensors	Các cảm biến
25	Video	Khả năng quay video
26	Launch	Thời điểm ra mắt
27	Year	Năm sản xuất
2.2.4. Biến thống kê bổ sung		
28	quantile_10	Phân vị 10% giá
29	quantile_50	Trung vị giá
30	quantile_90	Phân vị 90% giá
31	price_range	Phân khúc giá

2.3. Phân loại và vai trò của các biến số

2.3.1. Biến phụ thuộc (Y)

- Price (giá điện thoại) – Đây là biến mục tiêu chính của nghiên cứu, được sử dụng để đánh giá giá trị sản phẩm và là đầu ra mà mô hình học máy cần dự đoán. Giá phản ánh tổng hợp tác động của các yếu tố kỹ thuật và đặc điểm của điện thoại.

2.3.2. Biến độc lập định lượng (Xqt)

Bao gồm các biến số dạng số (numeric), được sử dụng để xây dựng mô hình hồi quy và phân tích tương quan, cụ thể như:

- RAM, Storage, BATTERY, Display_Size, PPI_Density, Weight, Year,...

Các biến này phản ánh trực tiếp hiệu năng và đặc điểm vật lý của điện thoại, có ảnh hưởng lớn đến giá sản phẩm. Chúng được sử dụng làm đầu vào chính cho các mô hình học máy.

2.3.3. Biến độc lập định tính (X_{ql})

Bao gồm các biến dạng phân loại (categorical), được sử dụng để phân nhóm và so sánh giữa các nhóm sản phẩm, bao gồm:

- Phone Brand, Store, OS, Chipset, CPU, GPU, Display_Type, Colors, USB,...

Các biến này thường được xử lý bằng phương pháp mã hóa (encoding) để đưa vào mô hình, đồng thời hỗ trợ phân tích sự khác biệt về giá giữa các nhóm.

2.3.4. Biến không sử dụng / cần loại bỏ (tránh data leakage)

Bao gồm các biến có liên quan trực tiếp đến biến mục tiêu hoặc được suy ra từ giá, cụ thể:

- price range, price_USD, currency, quantile_10, quantile_25, quantile_50, quantile_75, quantile_90

Các biến này có thể gây ra hiện tượng *data leakage* nếu đưa vào mô hình, làm sai lệch kết quả dự đoán và đánh giá.

2.3.5. Biến phát sinh (Feature Engineering)

Một số biến có thể được tạo thêm từ dữ liệu gốc nhằm cải thiện hiệu suất mô hình, ví dụ:

- Performance

Các biến này giúp mô hình học được các mối quan hệ phức tạp hơn giữa giá và thông số kỹ thuật.

Tổng thể, bộ dữ liệu cung cấp một cái nhìn toàn diện về các yếu tố ảnh hưởng đến giá điện thoại, phù hợp để áp dụng các phương pháp phân tích dữ liệu, mô hình hồi quy và học máy. Việc phân loại biến rõ ràng giúp nâng cao hiệu quả mô hình và đảm bảo tính chính xác trong quá trình nghiên cứu.

CHƯƠNG 3: GIỚI THIỆU VỀ MÔ HÌNH

3.1. Tổng quan về Machine Learning

3.1.1. Khái niệm Machine Learning

Học máy (Machine Learning – ML) là một nhánh quan trọng của trí tuệ nhân tạo (Artificial Intelligence – AI), cho phép các hệ thống máy tính có khả năng học hỏi từ dữ liệu mà không cần được lập trình một cách tường minh theo từng quy tắc cụ thể. Thay vì dựa vào các câu lệnh cố định, các mô hình học máy sử dụng dữ liệu đầu vào (input) để tự động phát hiện ra các quy luật, mối quan hệ tiềm ẩn và xu hướng bên trong dữ liệu, từ đó đưa ra các dự đoán hoặc quyết định.

Trong bối cảnh hiện nay, học máy đã được ứng dụng rộng rãi trong nhiều lĩnh vực như tài chính (dự báo cổ phiếu), y tế (chẩn đoán bệnh), thương mại điện tử (hệ thống gợi ý sản phẩm) và đặc biệt là các bài toán dự đoán và phân tích dữ liệu thị trường.

3.1.2. Supervised Learning

Học có giám sát là một trong những phương pháp phổ biến và hiệu quả nhất trong học máy. Phương pháp này yêu cầu dữ liệu huấn luyện đã được gán nhãn (labeled data). Cụ thể, mỗi quan sát trong tập dữ liệu bao gồm:

- Biến đầu vào (Features - X): Các đặc trưng hoặc thuộc tính của đối tượng.
- Biến mục tiêu (Target - y): Nhãn hoặc giá trị cần dự đoán tương ứng.

Mục tiêu của mô hình học có giám sát là học được một hàm ánh xạ $f: X \rightarrow y$ sao cho có thể dự đoán chính xác giá trị của y đối với các dữ liệu mới chưa từng thấy. Học có giám sát được chia thành hai loại bài toán chính:

- Bài toán phân loại (Classification): Dự đoán một biến đầu ra rời rạc, như phân loại email là "spam" hay "không spam", hoặc phân loại điện thoại vào các phân khúc "giá thấp", "giá trung bình", "giá cao".
- Bài toán hồi quy (Regression): Dự đoán một biến đầu ra liên tục, như dự đoán giá nhà, nhiệt độ, hoặc trong nghiên cứu này là giá điện thoại.

3.1.3. Bài toán hồi quy (Regression Problem)

Nghiên cứu này tập trung giải quyết bài toán hồi quy, với mục tiêu chính là dự đoán giá của một chiếc điện thoại thông minh – một biến mục tiêu có giá trị liên tục. Giả sử chúng ta có một tập dữ liệu bao gồm các thông số kỹ thuật của điện thoại (RAM, dung lượng pin, bộ nhớ trong, kích thước màn hình, v.v.). Mô hình hồi quy sẽ học một hàm có dạng tổng quát như sau:

$$y = f(X) + \epsilon$$

Trong đó:

- y : Giá điện thoại (biến mục tiêu).
- X : Tập hợp các đặc trưng đầu vào (các thông số kỹ thuật).
- f : Hàm ánh xạ từ đầu vào đến đầu ra được học bởi mô hình.
- ϵ : Sai số (phần chênh lệch giữa giá trị thực tế và dự đoán).

Bài toán hồi quy thường có độ phức tạp cao do mối quan hệ giữa các biến có thể mang tính phi tuyến và chịu ảnh hưởng bởi nhiều yếu tố tương tác lẫn nhau.

3.2. Các mô hình Học máy được sử dụng trong nghiên cứu

3.2.1. Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính là một trong những mô hình cơ bản và phổ biến nhất trong học máy, được sử dụng để mô tả mối quan hệ tuyến tính giữa biến phụ thuộc và các biến độc lập.

Mô hình có dạng:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$$

Trong đó:

- β_0 : Hệ số chặn
- β_i : Hệ số hồi quy
- x_i : Biến đầu vào

Ưu điểm:

- Dễ hiểu, dễ triển khai và diễn giải.
- Thời gian huấn luyện và dự đoán nhanh

Nhược điểm:

- Không thể hiệu quả với các mối quan hệ phi tuyến tính phức tạp.
- Nhạy cảm với các giá trị ngoại lai (outliers).

Trong nghiên cứu này, Linear Regression được sử dụng như một mô hình baseline để so sánh với các mô hình phức tạp hơn.

3.2.2. Cây quyết định (Decision Tree)

Decision Tree là mô hình học máy dựa trên cấu trúc cây, trong đó dữ liệu được phân chia thành các nhánh dựa trên giá trị của các biến đầu vào.

Mỗi nút trong cây đại diện cho một điều kiện kiểm tra, và mỗi nhánh tương ứng với một kết quả của điều kiện đó. Quá trình xây dựng cây nhằm mục tiêu giảm thiểu sai số dự đoán tại mỗi bước phân chia.

Ưu điểm:

- Dễ hiểu và dễ trực quan hóa.
- Có khả năng xử lý dữ liệu phi tuyến
- Không yêu cầu chuẩn hóa dữ liệu

Nhược điểm:

- Dễ bị overfitting nếu cây quá sâu
- Nhạy cảm với thay đổi nhỏ trong dữ liệu

3.2.3. Random Forest

Random Forest là một phương pháp học kết hợp (ensemble learning) hoạt động bằng cách xây dựng một số lượng lớn các cây quyết định trong quá trình huấn luyện. Để dự đoán, Random Forest kết hợp kết quả đầu ra của tất cả các cây con (ví dụ: lấy giá trị trung bình cho bài toán hồi quy).

Nguyên lý hoạt động:

- Tạo ra nhiều tập dữ liệu con khác nhau từ tập dữ liệu gốc bằng kỹ thuật lấy mẫu Bootstrap.
- Xây dựng một cây quyết định trên mỗi tập dữ liệu con
- Khi dự đoán, tổng hợp kết quả từ tất cả các cây

Ưu điểm:

- Độ chính xác cao

- Giảm thiểu hiện tượng overfitting hiệu quả
- Xử lý tốt dữ liệu có số chiều lớn và phi tuyến tính

Nhược điểm:

- Khó diễn giải hơn so với một cây quyết định
- Yêu cầu nhiều tài nguyên tính toán và bộ nhớ hơn

3.2.4. XGBoost (Extreme Gradient Boosting)

XGBoost là một thuật toán boosting mạnh mẽ và phổ biến, được xây dựng dựa trên nguyên lý Gradient Boosting. Đây là một trong những mô hình hàng đầu cho các bài toán học có giám sát với dữ liệu dạng bảng.

Nguyên lý:

- Xây dựng các mô hình yếu (weak learners) theo tuần tự
- Mỗi mô hình mới được thêm vào để khắc phục và "học" từ những sai lầm của các mô hình trước đó

Ưu điểm:

- Hiệu suất dự đoán vượt trội, thường đạt kết quả tốt nhất trong nhiều cuộc thi
- Xử lý tốt dữ liệu lớn với tốc độ nhanh
- Tích hợp cơ chế regularization (chống overfitting) ngay trong hàm mục tiêu

Nhược điểm:

- Có nhiều siêu tham số (hyperparameters) cần điều chỉnh
- Phức tạp hơn về mặt lý thuyết so với Random Forest

Trong nghiên cứu này, XGBoost được kỳ vọng sẽ cho kết quả dự đoán chính xác nhất nhờ khả năng xử lý các mối quan hệ phức tạp trong dữ liệu thông số điện thoại.

3.3. Hàm mất mát và chỉ số đánh giá

3.3.1. Mean Absolute Error (MAE)

MAE đo lường độ lớn trung bình của các sai số dự đoán, không quan tâm đến hướng của sai số (âm hay dương).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Trong đó: y_i là giá trị thực, $\hat{y}_i$ là giá trị dự đoán, n là số lượng mẫu.
- Đặc điểm: Dễ hiểu, trực quan, ít nhạy cảm với các giá trị ngoại lai.

3.3.2. Root Mean Squared Error (RMSE)

RMSE phạt nặng các sai số lớn do bình phương các sai số trước khi tính trung bình.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Đặc điểm: Nhạy cảm với các giá trị ngoại lai, phản ánh tốt sai số lớn. Có cùng đơn vị với biến mục tiêu.


3.3.3. Hệ số xác định (R^2)

R^2 đo lường tỷ lệ phương sai của biến phụ thuộc được giải thích bởi mô hình

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

- Trong đó: $SS_{res} = \sum (y_i - \hat{y}_i)^2$ là tổng bình phương phần dư, $SS_{tot} = \sum (y_i - \bar{y})^2$ là tổng bình phương toàn phần.
- Đặc điểm: Giá trị R^2 càng gần 1 cho thấy mô hình càng giải thích được nhiều sự biến thiên của dữ liệu, càng tốt.

3.4. Quy trình xây dựng mô hình



Dựa trên quy trình chung trong học máy và logic thuật toán, quá trình xây dựng mô hình bao gồm các bước:

- **Bước 1 - Thu thập dữ liệu:** Tập hợp dữ liệu thô từ các nguồn như file MobilePhone.xlsx.
- **Bước 2 - Tiền xử lý dữ liệu:** Làm sạch và chuẩn hóa dữ liệu để sẵn sàng cho mô hình. Bao gồm xử lý ô trống, chuẩn hóa các cột số (đưa về cùng tỷ lệ), và mã hóa các cột chữ (ví dụ: tên hãng, hệ điều hành) thành dạng số.
- **Bước 3 - Chia tập dữ liệu:** Chia dữ liệu thành hai phần riêng biệt: tập huấn luyện (Training Set) để mô hình "học" và tập kiểm tra (Test Set) để đánh giá khách quan hiệu suất của mô hình sau khi học. Tỷ lệ phổ biến là 80% cho huấn luyện và 20% cho kiểm tra.
- **Bước 4 - Huấn luyện mô hình:** Lần lượt huấn luyện 4 mô hình (Linear Regression, Decision Tree, Random Forest, XGBoost) trên tập huấn luyện.

- **Bước 5 - Đánh giá & So sánh:** Sử dụng các chỉ số MAE, RMSE, R^2 để đánh giá hiệu suất của từng mô hình trên tập kiểm tra. So sánh để xem mô hình nào cho kết quả tốt nhất.
- **Bước 6 - Tối ưu mô hình:** Nếu kết quả chưa tốt, thực hiện tối ưu siêu tham số cho các mô hình (đặc biệt là Random Forest và XGBoost) bằng các phương pháp như Grid Search, Random Search hoặc Giải thuật di truyền (Genetic Algorithm). Sau khi tối ưu, quay lại bước 4 để huấn luyện lại mô hình với siêu tham số mới.
- **Bước 7 - Kết luận và Ứng dụng:** Chọn ra mô hình có hiệu suất tốt nhất (dự kiến là XGBoost sau khi tối ưu) và sử dụng nó để dự đoán giá cho các mẫu điện thoại mới.

CHƯƠNG 4: XỬ LÝ DỮ LIỆU

4.1. Tiền xử lý dữ liệu

4.1.1. Kiểm tra dữ liệu rỗng

- Tìm giá trị thiếu: Sử dụng các hàm kiểm tra dữ liệu (như `isnull().sum()`) để xác định tổng số và vị trí các giá trị bị khuyết trong tập dữ liệu.
- Xử lý theo thương hiệu (`phone_brand`): Thay vì sử dụng giá trị trung bình chung cho toàn bộ tập dữ liệu, hãy thực hiện tính toán theo từng nhóm thương hiệu để đảm bảo tính chính xác.
 - o Đối với biến định lượng: Thay thế các giá trị thiếu bằng giá trị trung bình (mean) của các quan sát thuộc cùng một thương hiệu.
 - o Đối với biến định tính: Thay thế bằng yếu vị (mode), tức là giá trị xuất hiện thường xuyên nhất trong nhóm thương hiệu đó.
- Xóa các giá trị thiếu còn lại: Trong trường hợp một thương hiệu cụ thể (ví dụ: Asus) không có đủ dữ liệu để tính toán mean hoặc mode (ví dụ: tất cả bản ghi của hãng đó đều bị khuyết ở cột đó), quy trình là tiến hành xóa bỏ (drop) các bản ghi này để tránh sai lệch cho mô hình

4.1.2. Xử lý dữ liệu trùng

- Kiểm tra dữ liệu trùng lặp (duplicate records) bằng hàm `drop_duplicates()` trong thư viện Pandas. Kết quả cho thấy không phát hiện bất kỳ dòng dữ liệu trùng lặp nào trong tập dữ liệu. Do đó, không cần thực hiện thao tác loại bỏ dữ liệu trùng lặp, toàn bộ các quan sát đều là duy nhất và có giá trị sử dụng.

4.1.3. Chuẩn hóa dữ liệu

- Trong bước tiền xử lý, dữ liệu được chuẩn hóa nhằm đảm bảo tính nhất quán và giảm sai lệch trong quá trình phân tích. Cụ thể, biến `phone_brand` được chuyển toàn bộ về chữ thường (*lowercase*) để tránh tình trạng cùng một hãng nhưng bị ghi nhận dưới nhiều dạng khác nhau (ví dụ: “Samsung”, “SAMSUNG”, “samsung”).
- Bên cạnh đó, các giá trị không đồng nhất trong tập dữ liệu cũng được xử lý bằng cách loại bỏ khoảng trắng dư thừa ở đầu và cuối chuỗi. Việc này giúp đồng nhất định dạng dữ liệu, hạn chế lỗi khi phân nhóm và nâng cao độ chính xác của các bước phân tích và xây dựng mô hình sau này.

4.1.4. Loại bỏ dữ liệu sai

- Trong quá trình tiền xử lý, các quan sát không hợp lệ được loại bỏ nhằm đảm bảo độ tin cậy của dữ liệu đầu vào. Cụ thể, những bản ghi có giá (`price`) nhỏ hơn hoặc bằng 0 được xem là không có ý nghĩa thực tế và bị loại khỏi tập dữ liệu.
- Ngoài ra, các giá trị bất hợp lý ở một số biến kỹ thuật cũng được xử lý, chẳng hạn như RAM hoặc dung lượng pin (`BATTERY`) nhỏ hơn hoặc bằng 0. Đây là những trường hợp không tồn tại trong thực tế, do đó cần được loại bỏ để tránh gây sai lệch kết quả phân tích.
- Việc làm sạch dữ liệu theo các tiêu chí trên giúp nâng cao chất lượng dữ liệu, đảm bảo mô hình học máy được huấn luyện trên tập dữ liệu chính xác và phản ánh đúng thực tế thị trường.

4.1.5. Kiểm tra tương quan

4.1.5.1. Mối quan hệ với biến mục tiêu (*price*)

- `price` và `price_USD` (~0.99) có tương quan gần như hoàn hảo → hai biến này gần như trùng lặp thông tin, chỉ nên giữ một biến trong mô hình.
- `storage` (0.67) và `ram` (0.54) có tương quan dương khá mạnh với giá → đây là các yếu tố quan trọng ảnh hưởng đến giá điện thoại.
- `Foldable` (0.45) và `PPI_Density` (0.38) cũng có tương quan dương đáng kể → điện thoại màn hình gập và mật độ điểm ảnh cao thường có giá cao hơn.
- `Display_Size` (0.29) và `Year` (0.27) có tương quan dương mức trung bình → các dòng máy mới và màn hình lớn có xu hướng giá cao hơn.
- `Battery` (-0.12) có tương quan âm nhẹ → dung lượng pin không phải yếu tố quyết định giá trong dataset này.

4.1.5.2. *Tương quan giữa các biến độc lập (đa cộng tuyến)*

- Weight và Display_Size (0.75) có tương quan cao → điện thoại màn hình lớn thường nặng hơn.
- Display_Size và Battery (0.61) → màn hình lớn thường đi kèm pin lớn.
- Year và quantile_50 (0.81) → các biến phân vị giá có liên hệ mạnh với thời gian, nhưng đây là nhóm biến cần loại bỏ (do leakage).

Các cặp biến có tương quan cao có thể gây đa cộng tuyến, cần cân nhắc loại bớt hoặc dùng kỹ thuật giảm chiều.

4.1.6.3. *Các biến ít tương quan với giá*

- NFC (~0.22), Year (~0.27) → ảnh hưởng yếu đến giá.
- Một số biến có tương quan gần 0 hoặc âm nhẹ → ít giá trị dự báo.

4.1.6.4. *Cảnh báo Data Leakage*


- Các biến như quantile_10, quantile_50,... có tương quan với giá nhưng không được sử dụng trong mô hình vì được tính từ chính biến price.

4.1.6. Loại bỏ biến

- Tránh rò rỉ dữ liệu (Data Leakage): Việc loại bỏ các cột price_range, price_USD, currency là bắt buộc và chính xác. Đây là các biến biến thể của mục tiêu (Target), nếu giữ lại sẽ khiến mô hình "biết trước đáp án", dẫn đến kết quả ảo.
- Loại bỏ dữ liệu rác (Noise): Các cột quantile_10, 50, 90 (như đã thấy ở biểu đồ Boxplot trước đó có giá trị lên tới 10^{16}) là dữ liệu nhiễu hoặc lỗi hệ thống. Loại bỏ chúng giúp mô hình không bị sai lệch cực đoan.
- Tối ưu hóa đặc trưng: Việc rút gọn từ dữ liệu thô xuống 25 đặc trưng chất lượng giúp mô hình tập trung vào các thông số kỹ thuật cốt lõi (RAM, Pin, CPU...), làm tăng tính ổn định và khả năng giải thích của mô hình.


4.2. Phân tích dữ liệu (EDA)

4.2.1. Phân phối histogram




- Năm sản xuất (Year): Dữ liệu trải dài từ 2018 đến 2024, tập trung nhiều ở các năm gần đây (2022-2024), phản ánh xu hướng cập nhật các mẫu điện thoại mới.
- Trọng lượng (Weight): Biến động từ 135g đến 271g, cho thấy sự đa dạng về thiết kế (từ nhẹ như iPhone 12 mini đến nặng như các dòng gập hoặc gaming).
- Dung lượng pin (BATTERY): Dao động từ 1821 mAh đến 10200 mAh, cho thấy xu hướng trang bị pin lớn hơn ở các mẫu mới.
- Display_Size: Trung bình ~6.5 inch, màn hình lớn đang là xu hướng chủ đạo.
- Mật độ điểm ảnh (PPI_Density): Giá trị từ 179 đến 570, phản ánh chất lượng hiển thị khác nhau giữa các phân khúc.
- Các chỉ số phân vị (quantile_10, quantile_50, quantile_90): Có sự khác biệt rõ rệt, cho thấy dữ liệu không đồng đều và có độ phân tán cao, đặc biệt ở các phân khúc giá cao.


4.2.2. Boxplot



4.2.3. Scatter



4.2.4. Average price by phone_brand



4.2.4.1. Phân khúc Thương hiệu rõ rệt


Biểu đồ cho thấy sự phân hóa cực kỳ mạnh mẽ về mức giá giữa các hãng điện thoại, có thể chia làm 3 nhóm chính:

- Nhóm Cao cấp (Premium): Dẫn đầu là Google (cao nhất, sát mức 700), tiếp theo là Sony, Huawei, Apple và Honor.
- Nhóm Tầm trung (Mid-range): Bao gồm Samsung, Vivo, ZTE, OnePlus và Nothing. Mức giá trung bình dao động từ 350 - 550.
 - o *Nhận xét:* Samsung có dải sản phẩm rất rộng, nên mức giá trung bình quanh 400 là hợp lý vì nó bao gồm cả dòng A (giá rẻ) và dòng S/Z (cao cấp).
- Nhóm Giá rẻ/Phổ thông (Budget): Gồm có Infinix, TCL, Xiaomi, Nokia, Tecno, Cubot. Trong đó, Infinix và TCL có mức giá trung bình thấp nhất (dưới 150).

4.2.4.2. Những điểm bất ngờ (Insights)


- Xiaomi và Nokia: Hai thương hiệu này có mức giá trung bình khá thấp (dưới 250). Điều này cho thấy trong tập dữ liệu bạn thu thập, phần lớn máy của hai hãng này thuộc phân khúc phổ thông hoặc máy cũ.
- Sony và Huawei: Vẫn giữ vị thế giá rất cao (trên 600), cho thấy các sản phẩm của hai hãng này trong tập dữ liệu chủ yếu là các dòng Flagship hoặc máy có thông số kỹ thuật đặc biệt (như Camera).

4.2.4. Performance



- Biểu đồ cho thấy một xu hướng tăng rõ rệt (từ trái sang phải, từ dưới lên trên). Khi điểm Performance càng cao, giá điện thoại có xu hướng càng đắt.
- Có một số ít mẫu có Performance cực cao (16000 - có thể là máy 16GB RAM/1TB Storage) nhưng giá lại không phải là cao nhất.
- Ngược lại, có những máy mức Performance chỉ ở mức trung bình (6000 - 8000) nhưng giá lại chạm đỉnh (trên 2000). Đây khả năng cao là các dòng iPhone (Apple) hoặc điện thoại siêu sang có thiết kế đặc biệt.

4.2.4. Pairplot



CHƯƠNG 5: MÔ HÌNH HÓA DỮ LIỆU ĐÁNH GIÁ MÔ HÌNH

5.1. Chia dữ liệu

Kết quả chia dữ liệu cho thấy:

- Tập huấn luyện (Train set): 1178 quan sát
- Tập kiểm tra (Test set): 506 quan sát
- a) Tỷ lệ phân chia chuẩn: Chia theo tỷ lệ 70% Huấn luyện (Train) - 30% Kiểm tra (Test) là mức kinh điển, đảm bảo mô hình có đủ dữ liệu để học và đủ mẫu để đánh giá khách quan.
- b) Kỹ thuật mã hóa biến giả (Dummy Variables): Sử dụng `drop_first=True` là lựa chọn chính xác để tránh hiện tượng đa cộng tuyến (Dummy Variable Trap), giúp mô hình ổn định hơn.
- c) Tính nhất quán cao: Sử dụng `random_state=42` giúp kết quả phân chia dữ liệu luôn cố định, đảm bảo việc so sánh giữa các thuật toán (LR, RF, XGBoost) là công bằng và có thể tái lập.

5.2. Linear Regression

- Dựa trên các hình ảnh mới bạn cung cấp, đây là bản đánh giá chi tiết mô hình Linear Regression sau khi bạn đã thực hiện một số điều chỉnh (có vẻ như bạn đã loại bỏ biến rời rã dữ liệu `price_USD` vì chỉ số R^2 đã thực tế hơn).

5.2.1. Phân tích chỉ số hiệu năng (Metrics)

```
--- Test Set Metrics ---
MAE (Test): 94.60225987472562
RMSE (Test): 149.5861496770917
R2 (Test): 0.7639607269568092

--- Train Set Metrics ---
MAE (Train): 57.379311876787156
RMSE (Train): 95.11492676059075
R2 (Train): 0.923143660799546
```

- R^2 (Độ phù hợp):
 - Train set: 0.923 (92.3%)
 - Test set: 0.764 (76.4%)

- Nhận xét: Có sự chênh lệch đáng kể giữa Train và Test (~16%). Điều này cho thấy mô hình đang bị Overfitting (Quá khớp). Mô hình học rất tốt trên dữ liệu cũ nhưng khi gặp dữ liệu mới (Test set) thì độ chính xác giảm đi rõ rệt. Tuy nhiên, mức 0.76 đã là một sự cải thiện rất lớn so với mức 0.08 trước đó.
- Sai số (MAE & RMSE):
 - MAE trên tập Test là 94.6. Nghĩa là trung bình mỗi dự báo lệch khoảng 94.6 đơn vị tiền tệ. Tùy vào giá trị của mặt hàng mà đây có thể là con số lớn hoặc nhỏ (nếu điện thoại giá 200 mà lệch 94 thì sai số lên tới gần 50%).


5.2.2. Phân tích bảng hệ số (Coefficients)

- Các biến quan trọng nhất: store_Best Buy, store_Samsung, store_Motorola.
- Vấn đề: Mô hình đang bị phụ thuộc quá nhiều vào nơi bán (store) hơn là thông số kỹ thuật.
 - Ví dụ: Biến store_Best Buy có hệ số tậ 388.9. Điều này có nghĩa là "chỉ cần máy được bán tại Best Buy, giá dự báo sẽ tự động tăng thêm 388 đơn vị", bất chấp cấu hình.
 - Biến Foldable (điện thoại gập) đứng thứ 4 với hệ số 198.0 là hợp lý, vì công nghệ này đắt tiền.

	price	pred	residual
1216	199.00	300.972315	-101.972315
1184	127.89	318.627134	-190.737134
578	64.95	-61.882990	126.832990
51	149.98	140.875851	9.104149
1551	154.50	131.764580	22.735420

- Dự báo giá trị âm: Nhìn vào bảng so sánh, tại dòng index 578, giá thực là 64.95 nhưng mô hình dự báo là -61.88.
 - Lỗi nghiêm trọng: Trong thực tế không có điện thoại giá âm. Đây là điểm yếu chí tử của Linear Regression khi gặp dữ liệu không có tính tuyến tính thuần túy.

5.2.3. Phân tích biểu đồ phần dư (Residual Plot)



- Đây là biểu đồ quan trọng nhất để đánh giá một mô hình hồi quy tuyến tính:
- Hình dạng "Cái phễu" (Heteroscedasticity): Bạn có thể thấy các điểm đỏ tỏa ra rộng hơn khi giá trị dự báo (Predicted Price) tăng lên.
 - Ý nghĩa: Mô hình dự báo khá ổn ở phân khúc giá thấp, nhưng khi giá càng cao, sai số càng lớn và mất kiểm soát. Điều này vi phạm giả định quan trọng của Linear Regression (phương sai của sai số phải không đổi).
- Các điểm ngoại lai (Outliers): Có một vài điểm có phần dư (Residual) lên tới 750 - 1000. Đây là những máy mà mô hình dự báo sai lệch cực kỳ nặng nề.

5.3. Decision Tree

5.3.1. Hiện tượng Overfitting (Quá khớp) cực đoan

Đây là đặc điểm nổi bật nhất của mô hình này:

```
--- Test Set Metrics (Decision Tree) ---
MAE (Test): 102.51743083003953
RMSE (Test): 174.22372562754333
R2 (Test): 0.6798038585124495
```

```
--- Train Set Metrics (Decision Tree) ---
MAE (Train): 0.0
RMSE (Train): 0.0
R2 (Train): 1.0
```


- Tập Train: $R^2 = 1.0$, $MAE = 0.0$, $RMSE = 0.0$. Mô hình dự báo chính xác tuyệt đối 100% trên tập huấn luyện.
- Tập Test: $R^2 \approx 0.68$, $MAE \approx 102.5$.
- Nhận xét: Đây là minh chứng rõ ràng của một cái cây được phát triển quá sâu (không giới hạn độ sâu). Mô hình đã "học thuộc lòng" toàn bộ dữ liệu nhiễu của tập Train thay vì học quy luật chung. Do đó, khi áp dụng vào tập Test, độ chính xác giảm mạnh từ 100% xuống còn 68%.

5.3.2. Phân tích bảng so sánh giá trị dự báo

	price	pred	residual
1216	199.00	233.53	-34.53
1184	127.89	204.99	-77.10
578	64.95	56.87	8.08
51	149.98	121.27	28.71
1551	154.50	268.00	-113.50

- Độ lệch lớn: Tại dòng 1551, giá thực là 154.50 nhưng dự báo lên tới 268.00 (lệch gần gấp đôi).
- Độ chính xác cục bộ: Tại dòng 578, dự báo 56.87 cho mức giá thực 64.95 là khá ổn.
- Đặc điểm của cây: Bạn có thể thấy các con số dự báo của Decision Tree thường là những con số cụ thể (do nó lấy giá trị trung bình của các mẫu tại nút lá). Điều này khiến dự báo đôi khi bị "nhảy bậc" chứ không mượt mà như các mô hình hồi quy khác.

5.3.3. Phân tích biểu đồ phần dư (Residual Plot)



- Sai số không đồng đều: Ở vùng giá thấp (0 - 500), các điểm đỏ tập trung dày quanh đường 0. Tuy nhiên, khi giá trị dự báo tăng lên, sai số bắt đầu "nổ" ra rất lớn.
- Nhiều điểm ngoại lai (Outliers) cực đoan: Có những điểm phần dư lên tới hơn 1250 đơn vị. Điều này chứng tỏ với những dòng điện thoại cao cấp hoặc có đặc điểm lạ, Decision Tree hoàn toàn "bỏ tay" và đưa ra những dự báo sai lệch khủng khiếp.
- Cấu trúc dữ liệu: Các điểm đỏ tạo thành các cụm thẳng đứng, cho thấy mô hình đang bị kẹt vào một số quy tắc cứng nhắc của các nút lá.

5.3.4. Đánh giá tính ứng dụng trong nghiên cứu

Mô hình Decision Tree ở trạng thái mặc định này không đạt yêu cầu để đưa vào ứng dụng thực tế do lỗi quá khớp quá nặng.

5.4. Random Forest

5.4.1. Phân tích chỉ số hiệu năng (Metrics) - Sự cải thiện vượt trội

```
--- Test Set Metrics (Random Forest) ---
MAE (Test): 80.73467312252966
RMSE (Test): 129.29873787249235
R2 (Test): 0.8236440680280113

--- Train Set Metrics (Random Forest) ---
MAE (Train): 34.367453735144295
RMSE (Train): 56.21922202243177
R2 (Train): 0.9731495232322465
```


- R^2 (Độ phù hợp):
 - Test set: 0.8236 (82.36%). Đây là mức rất tốt cho bài toán định giá. Nó giải thích được hơn 82% sự biến động của giá điện thoại dựa trên các thông số kỹ thuật. Nó vượt xa Linear Regression (76%) và Decision Tree (68%).
 - Train set: 0.9731 (97.31%).
- Sai số (MAE & RMSE):
 - MAE (Test) = 80.73: Sai số trung bình đã giảm xuống mức thấp nhất (so với 94.6 của LR và 102.5 của DT). Điều này có nghĩa là các dự báo của Random Forest sát với giá thực tế hơn rất nhiều.

5.4.2. Khả năng kiểm soát Overfitting

	price	pred	residual
1216	199.00	375.0665	-176.0665
1184	127.89	249.3487	-121.4587
578	64.95	135.4007	-70.4507
51	149.98	125.1829	24.7971
1551	154.50	158.1004	-3.6004

- Dự báo cực kỳ sát: Tại dòng 1551, giá thực là 154.50, mô hình dự báo 158.10. Sai số chỉ là -3.6 đơn vị (khoảng 2%). Đây là một kết quả ấn tượng.
- Tính thực tiễn: Mô hình không hề gặp lỗi dự báo giá âm, đảm bảo tính logic trong kinh doanh. Tuy nhiên, ở dòng 1216, mô hình dự báo giá 375 cho máy 199, cho thấy với một số mẫu có thông số "đánh lừa", mô hình vẫn bị lệch.

5.4.3. Phân tích biểu đồ phần dư (Residual Plot)



- Độ tập trung: Các điểm đỏ tập trung quanh đường 0 dày đặc hơn và sát hơn so với các mô hình trước đó. Điều này chứng tỏ phần lớn các dự báo có sai số nhỏ.
- Tính ổn định: Mô hình dự báo cực kỳ chính xác ở phân khúc giá từ 0 - 750 đơn vị.
- Phân phối: Các sai số phân bố tương đối đều ở cả hai phía (âm và dương), cho thấy mô hình không bị lệch hệ thống (không luôn dự báo quá cao hay quá thấp).
- Điểm yếu còn tồn tại: Hiện tượng "hình phễu" vẫn xuất hiện nhẹ. Khi giá trị dự báo cao (trên 1000), sai số bắt đầu lớn dần. Điều này dễ hiểu vì các dòng điện thoại siêu cao cấp (Luxury/Flagship) thường có mức giá biến động rất lớn và khó đoán định chỉ dựa trên thông số kỹ thuật thuần túy.

5.5. XGBoost

5.5.1. Phân tích chỉ số hiệu năng (Metrics) - Đỉnh cao mới

```
--- Test Set Metrics (XGBoost Regressor) ---
MAE (Test): 74.29935853679191
RMSE (Test): 121.59817433446058
R2 (Test): 0.8440247788171661

--- Train Set Metrics (XGBoost Regressor) ---
MAE (Train): 33.90931114468793
RMSE (Train): 47.35847229170328
R2 (Train): 0.980946370881577
```

- R^2 (Độ phù hợp):
 - Test set: 0.8440 (84.4%). Đây là chỉ số cao nhất từ trước đến nay (Random Forest đạt 82.3%, Linear Regression đạt 76%). Với mức 84.4%, mô hình này cực kỳ mạnh mẽ trong việc giải thích sự biến động của giá điện thoại.
 - Train set: 0.9809 (98.1%).
- Sai số (MAE & RMSE):
 - MAE (Test) = 74.29: Đây là mức sai số thấp nhất trong tất cả các mô hình. Trung bình, mô hình chỉ lệch khoảng 74 đơn vị giá cho mỗi dự báo.

5.5.2. Khả năng tổng quát hóa (Generalization)


- Mặc dù kết quả tập Train rất cao (98%), nhưng kết quả tập Test vẫn duy trì được ở mức 84.4%. Khoảng cách này cho thấy XGBoost đã sử dụng các kỹ thuật Regularization (L1, L2) nội tại rất tốt để kiểm soát Overfitting, giúp nó hoạt động ổn định hơn hẳn so với Decision Tree.

5.5.3. Phân tích bảng giá trị dự báo (Predictions)

	price	pred	residual
1216	199.00	386.830292	-187.830292
1184	127.89	234.908340	-107.018340
578	64.95	152.997711	-88.047711
51	149.98	167.697571	-17.717571
1551	154.50	156.480347	-1.980347


- Độ chính xác ấn tượng: Hãy nhìn vào dòng index 1551: Giá thực tế là 154.50, XGBoost dự báo 156.48. Sai số chỉ là -1.98 đơn vị (chưa đến 1.3%). Đây là một kết quả gần như hoàn hảo.
- Cải thiện phân khúc giá thấp: Ở dòng index 51, giá thực 149.98, dự báo 167.69. Sai số được thu hẹp đáng kể so với các mô hình trước đó.
- Vẫn còn sai số ở một vài điểm: Dòng index 1216 vẫn có sai số khá lớn (-187), cho thấy vẫn có những mẫu điện thoại có đặc điểm "dị" mà thông số kỹ thuật chưa giải thích hết được.

5.5.4. Phân tích biểu đồ phần dư (Residual Plot)



- Độ tập trung: Các điểm dữ liệu hội tụ quanh đường 0 chặt chẽ hơn bất kỳ mô hình nào trước đó. Điều này chứng tỏ XGBoost đã học được các quy luật tinh vi mà các thuật toán khác bỏ lỡ.
- Phân phối: Đa số các dự báo nằm trong khoảng sai số ± 200 .
- Ngoại lai (Outliers): Vẫn còn một số điểm bay xa ($\text{Residual} > 800$), nhưng số lượng ít hơn hẳn so với AdaBoost hay Decision Tree.

5.5.5. Trực quan hóa



a) Yếu tố phần cứng cốt lõi: Storage và RAM

- Storage (192.0) & RAM (112.0): Không ngoài dự đoán, đây là hai thông số kỹ thuật quan trọng nhất.
 - o Nhận xét: storage có điểm F-score cao nhất tuyệt đối. Điều này cực kỳ hợp lý vì các hãng điện thoại thường phân cấp giá rất rõ rệt dựa trên dung lượng bộ nhớ (ví dụ: bản 256GB luôn đắt hơn bản 128GB). ram đứng thứ 4, cho thấy đây là tiêu chí quan trọng thứ hai để xác định sức mạnh và phân khúc giá của máy.

b) Yếu tố thị trường và Kênh phân phối (Store)

- store_Amazon DE (179.0), US (90.0), UK (81.0): Các biến này chiếm vị trí rất cao trong top 6.
 - o Nhận xét: Điều này cho thấy mô hình nhận diện được sự khác biệt về mức giá giữa các thị trường (Đức, Mỹ, Anh). Giá điện thoại không chỉ phụ thuộc vào cấu hình mà còn phụ thuộc vào thuế, phí vận chuyển và chính sách giá của từng khu vực/nền tảng. Việc Amazon DE đứng thứ 2 cho thấy dữ liệu của bạn có thể chứa nhiều mẫu máy từ thị trường Châu Âu với đặc thù giá riêng.

c) Yếu tố vật lý: Weight (165.0) và Display_Size (48.0)

- Weight (Trọng lượng): Đứng thứ 3 với điểm số rất cao (165.0).

- Giải mã: Tại sao trọng lượng lại quan trọng đến thế? Thông thường, các dòng điện thoại cao cấp (Flagship) sử dụng vật liệu đắt tiền như thép không gỉ, nhôm hàng không hoặc kính cường lực dày, cộng với viên pin lớn và hệ thống camera phức tạp, khiến máy nặng hơn. Ngược lại, máy giá rẻ thường làm bằng nhựa và nhẹ hơn. Mô hình đã "vô tình" dùng trọng lượng như một biến đại diện (proxy) cho chất lượng hoàn thiện của máy.

d) Yếu tố thời gian và Công nghệ màn hình

- Year (40.0): Năm sản xuất đóng góp một phần quan trọng. Điện thoại càng mới thì giá càng cao do công nghệ mới và chưa bị khấu hao.
- PPI_Density (31.0): Độ sắc nét của màn hình là một chỉ số định giá tốt. Màn hình độ phân giải cao thường chỉ xuất hiện trên các dòng máy đắt tiền.

e) Các yếu tố đặc biệt và Hệ điều hành

- OS_iOS 18 (9.0): Mặc dù điểm số thấp nhưng việc nó xuất hiện trong Top 15 là rất đáng chú ý.
 - Ý nghĩa: Nó đại diện cho "độ cao cấp" của thương hiệu Apple. Chỉ cần máy chạy iOS, giá của nó đã nằm ở một khung hoàn toàn khác so với mặt bằng chung Android.
- Video_1080p@30fps (8.0): Đây là một tính năng cơ bản, việc nó xuất hiện cho thấy mô hình dùng nó để phân loại các dòng máy cực rẻ (máy giá rẻ thường bị cắt giảm ở khả năng quay video).

5.6. So sánh mô hình

5.6.1. Bảng so sánh tổng hợp (Tập Test)

Mô hình	R^2 (Test)	MAE (Sai số TB)	Đánh giá chung
XGBoost Regressor	0.8440	74.29	Tốt nhất (Mô hình đề xuất)
Random Forest	0.8236	80.73	Rất tốt, ổn định
Linear Regression	0.7640	94.60	Khá, nhưng lỗi logic (giá âm)
Decision Tree	0.6798	102.51	Tệ (Bị quá khớp/Overfitting nặng)

5.6.2. Nhận xét chi tiết từng mô hình

a) Nhóm mô hình hiệu quả cao (XGBoost & Random Forest)

- XGBoost (Vô địch): Đây là mô hình tối ưu nhất. Với $R^2 = 84.4\%$, nó giải thích được hầu hết các yếu tố cấu thành giá điện thoại. Sai số MAE thấp nhất (74.29)

cho thấy các dự báo của nó rất sát với thực tế, đặc biệt là ở phân khúc máy tầm trung.

- Random Forest: Hoạt động rất ổn định. Nó giải quyết tốt các mối quan hệ phi tuyến tính giữa thông số kỹ thuật và giá cả. Ưu điểm lớn nhất là không bị dự báo giá trị âm và xử lý tốt các biến phân loại (như Thương hiệu, Cửa hàng).

b) Nhóm mô hình cơ bản (Linear Regression)

- Ưu điểm: Cho kết quả khá bất ngờ ($R^2 = 76.4\%$), chứng tỏ có một mối quan hệ tuyến tính nhất định giữa cấu hình (RAM, Bộ nhớ) và giá bán.
- Nhược điểm: Vi phạm các giả định thống kê (biểu đồ phần dư hình phễu). Đặc biệt, mô hình này dự báo giá âm cho các dòng máy cấu hình thấp, điều này hoàn toàn phi thực tế trong kinh doanh.

c) Nhóm mô hình kém hiệu quả (Decision Tree & AdaBoost)

- Decision Tree: Bị lỗi "học vẹt" (Overfitting). Nó khớp 100% trên tập Train nhưng giảm mạnh trên tập Test. Điều này xảy ra do cây quá sâu và số lượng đặc trưng (1935 cột) quá lớn khiến cây bị nhiễu.

5.6.3. Phân tích các yếu tố ảnh hưởng (Feature Importance)

Từ mô hình tốt nhất (XGBoost), chúng ta rút ra được các quy luật định giá điện thoại như sau:

- Dung lượng lưu trữ (Storage) là yếu tố số 1: Đây là biến có tác động mạnh nhất đến việc tăng/giảm giá thành.
- Trọng lượng (Weight) là biến gây bất ngờ: Trọng lượng máy đóng vai trò như một chỉ số đại diện cho chất lượng vật liệu (kim loại/kính vs nhựa) và phân khúc máy (Flagship thường nặng hơn).
- Kênh phân phối (Store): Giá điện thoại biến động rõ rệt theo từng khu vực địa lý (Đức, Mỹ, Anh), cho thấy yếu tố thị trường quan trọng không kém cấu hình phần cứng.

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Trong bối cảnh thị trường điện thoại thông minh ngày càng phát triển và cạnh tranh mạnh mẽ, việc xác định giá trị hợp lý của sản phẩm dựa trên các thông số kỹ thuật là một bài toán có ý nghĩa thực tiễn cao. Nghiên cứu này đã tập trung xây dựng và đánh giá các mô hình học máy nhằm dự đoán giá điện thoại dựa trên dữ liệu cấu hình kỹ thuật.

Trước hết, nghiên cứu đã tiến hành thu thập và xử lý bộ dữ liệu MobilePhone với nhiều biến đặc trưng như RAM, dung lượng bộ nhớ, pin, trọng lượng, mật độ điểm ảnh và các thông tin liên quan. Quá trình tiền xử lý dữ liệu được thực hiện cẩn thận bao gồm xử lý giá trị thiếu (thay thế bằng mean cho biến định lượng và mode cho biến định tính theo từng phone_brand, đồng thời loại bỏ các dòng không thể xử lý), kiểm tra và xác nhận không có dữ liệu trùng lặp, chuẩn hóa dữ liệu và mã hóa các biến phân loại, từ đó đảm bảo chất lượng dữ liệu đầu vào cho mô hình.

Tiếp theo, nghiên cứu đã triển khai và so sánh nhiều mô hình học máy khác nhau bao gồm Linear Regression, Decision Tree, Random Forest, XGBoost và AdaBoost. Kết quả thực nghiệm cho thấy các mô hình ensemble như Random Forest và XGBoost có hiệu suất vượt trội so với mô hình hồi quy tuyến tính, thể hiện qua các chỉ số đánh giá như MAE, RMSE và hệ số xác định R^2 . Điều này cho thấy các mô hình phi tuyến có khả năng nắm bắt tốt hơn mối quan hệ phức tạp giữa các biến đầu vào và giá sản phẩm.

Mô hình kiến nghị: Nên sử dụng XGBoost Regressor. Mô hình này hội tụ đủ các ưu điểm: độ chính xác cao nhất ($R^2 = 84.4\%$, MAE = 74.29), tốc độ xử lý tốt và khả năng tổng quát hóa dữ liệu mới ổn định. XGBoost vượt trội hơn hẳn so với các mô hình còn lại như Decision Tree (bị overfitting nặng) hay AdaBoost (sai số hệ thống lớn).

Ngoài ra, việc áp dụng các phương pháp tối ưu siêu tham số như Grid Search đã góp phần cải thiện đáng kể hiệu suất của mô hình, giảm sai số dự đoán và tăng khả năng tổng quát hóa. Phân tích tầm quan trọng của các đặc trưng cũng cho thấy các yếu tố như dung lượng lưu trữ (storage), RAM, trọng lượng máy và kênh phân phối có ảnh hưởng lớn đến giá điện thoại, phù hợp với thực tế thị trường.

Tổng thể, nghiên cứu đã chứng minh rằng việc ứng dụng học máy trong bài toán dự đoán giá điện thoại là khả thi và mang lại hiệu quả cao. Các kết quả đạt được không chỉ có giá trị về mặt học thuật mà còn có tiềm năng ứng dụng trong thực tiễn, đặc biệt trong các hệ thống thương mại điện tử và hỗ trợ ra quyết định kinh doanh.

6.2. Đóng góp của nghiên cứu

Nghiên cứu này đã đạt được một số đóng góp quan trọng như sau:

Thứ nhất, nghiên cứu đã xây dựng một quy trình hoàn chỉnh cho bài toán dự đoán giá điện thoại, bao gồm các bước từ tiền xử lý dữ liệu (xử lý missing value theo nhóm thương hiệu, chuẩn hóa, mã hóa), xây dựng mô hình, đánh giá đến tối ưu hóa. Quy trình này có thể được áp dụng cho các bài toán tương tự trong thực tế.

Thứ hai, nghiên cứu đã thực hiện so sánh nhiều mô hình học máy khác nhau trên cùng một tập dữ liệu (Linear Regression, Decision Tree, Random Forest, XGBoost, AdaBoost), từ đó xác định được XGBoost là mô hình phù hợp nhất cho bài toán. Điều này giúp cung cấp cơ sở tham khảo cho các nghiên cứu và ứng dụng sau này.

Thứ ba, bài nghiên cứu đã chứng minh rằng việc kết hợp giữa thông số kỹ thuật thuần túy (RAM, CPU, Pin, Storage) và yếu tố thị trường (kênh phân phối, năm sản xuất) thông qua thuật toán Boosting có thể tạo ra một hệ thống định giá tự động với độ tin cậy trên 84%. Đây là một kết quả ấn tượng, khẳng định tính khả thi của phương pháp đề xuất.

Thứ tư, việc phân tích tầm quan trọng của các đặc trưng đã mang lại những insight có giá trị, giúp hiểu rõ hơn về các yếu tố ảnh hưởng đến giá điện thoại. Đặc biệt, phát hiện về vai trò của trọng lượng máy như một chỉ số đại diện cho chất lượng vật liệu và phân khúc sản phẩm là một kết luận thú vị.

Thứ năm, nghiên cứu đã áp dụng kỹ thuật tối ưu siêu tham số nhằm nâng cao hiệu suất mô hình, thể hiện sự kết hợp giữa lý thuyết và thực nghiệm trong học máy.

6.3. Hạn chế của nghiên cứu

Bên cạnh những kết quả đạt được, nghiên cứu vẫn còn tồn tại một số hạn chế nhất định:

Thứ nhất, bộ dữ liệu sử dụng trong nghiên cứu chưa thực sự lớn và có thể chưa phản ánh đầy đủ sự đa dạng của thị trường điện thoại. Điều này có thể ảnh hưởng đến khả năng tổng quát hóa của mô hình.

Thứ hai, nghiên cứu chỉ tập trung vào các thông số kỹ thuật mà chưa xem xét đến các yếu tố khác như thương hiệu, xu hướng thị trường, chiến lược marketing hay đánh giá của người dùng – những yếu tố có thể ảnh hưởng đáng kể đến giá sản phẩm.

Thứ ba, các mô hình được sử dụng chủ yếu là các mô hình học máy truyền thống, chưa khai thác các phương pháp học sâu (Deep Learning) hoặc các mô hình đa phương thức.

Thứ tư, việc tối ưu hóa siêu tham số vẫn còn giới hạn trong các phương pháp cơ bản như Grid Search, chưa áp dụng các phương pháp tối ưu nâng cao như Bayesian Optimization hoặc các thuật toán tiến hóa một cách toàn diện.

Thứ năm, mô hình AdaBoost cho thấy sự thất bại do quá nhạy cảm với các giá trị ngoại lai (outliers) trong dữ liệu, đặc biệt là các mẫu điện thoại cực đắt hoặc cực rẻ. Điều này cho thấy cần có chiến lược xử lý outliers phù hợp hơn.

6.4. Hướng phát triển trong tương lai

Để khắc phục các hạn chế và nâng cao hiệu quả của mô hình, nghiên cứu có thể được mở rộng theo các hướng sau:

Thứ nhất, mở rộng và cập nhật bộ dữ liệu với quy mô lớn hơn, bao gồm nhiều dòng điện thoại mới và đa dạng hơn về thương hiệu cũng như phân khúc giá. Điều này sẽ giúp cải thiện khả năng học và tổng quát hóa của mô hình.

Thứ hai, tập trung vào việc làm sạch và xử lý các giá trị ngoại lai (outliers) ở phân khúc giá cao và giá thấp để cải thiện độ chính xác, đặc biệt cho các mô hình nhạy cảm như AdaBoost.

Thứ ba, tích hợp thêm các loại dữ liệu khác như:

- Dữ liệu hình ảnh sản phẩm (thiết kế, màu sắc, cụm camera)
- Dữ liệu văn bản (mô tả sản phẩm, đánh giá người dùng)

Từ đó xây dựng các mô hình học máy đa phương thức (Multimodal Machine Learning) nhằm khai thác thông tin một cách toàn diện hơn.

Thứ tư, áp dụng các mô hình học sâu (Deep Learning) như Neural Networks hoặc các kiến trúc tiên tiến như Transformer để cải thiện khả năng dự đoán trong các bài toán phức tạp.

Thứ năm, sử dụng các phương pháp tối ưu hóa siêu tham số nâng cao như Bayesian Optimization hoặc Genetic Algorithm nhằm tìm kiếm cấu hình tối ưu hiệu quả hơn, từ đó nâng cao hiệu suất của XGBoost và các mô hình khác.

Thứ sáu, phát triển hệ thống ứng dụng thực tế như:

- Hệ thống định giá tự động cho sản phẩm điện thoại
- Hệ thống gợi ý sản phẩm trong thương mại điện tử
- Công cụ hỗ trợ người tiêu dùng so sánh giá

6.5. Kết luận chung

Nghiên cứu đã đạt được mục tiêu đề ra là xây dựng và đánh giá các mô hình học máy trong bài toán dự đoán giá điện thoại dựa trên thông số kỹ thuật. Kết quả cho thấy học máy là một công cụ hiệu quả trong việc giải quyết các bài toán dự đoán phức tạp, đặc biệt khi dữ liệu có mối quan hệ phi tuyến.

Thông qua việc so sánh các mô hình và phân tích kết quả, nghiên cứu đã chỉ ra rằng XGBoost là mô hình phù hợp nhất cho bài toán định giá điện thoại, với độ chính xác cao nhất ($R^2 = 84.4\%$) và sai số thấp nhất ($MAE = 74.29$). Mô hình này hội tụ đủ các ưu điểm: độ chính xác cao, tốc độ xử lý tốt và khả năng tổng quát hóa dữ liệu mới ổn định.

Mô hình kiến nghị sử dụng: XGBoost Regressor.

Đồng thời, nghiên cứu cũng mở ra nhiều hướng phát triển tiềm năng trong tương lai, góp phần nâng cao giá trị ứng dụng của học máy trong lĩnh vực thương mại điện tử và hỗ trợ ra quyết định kinh doanh.